UNIVERZITET U NOVOM SADU
FAKULTET TEHNIČKIH NAUKA

Projektni izveštaj

Metode i tehnike dubokog učenja

Reprodukcija i evaluacija rada: *Learning Long-Range Action Representation by Two-Stream Mamba Pyramid Network for Figure Skating Assessment*

Profesor: Dubravko Ćulibrk
Student: Andrijana Koljanin I720/2025

Novi Sad, 2026.

1. Uvod i motivacija

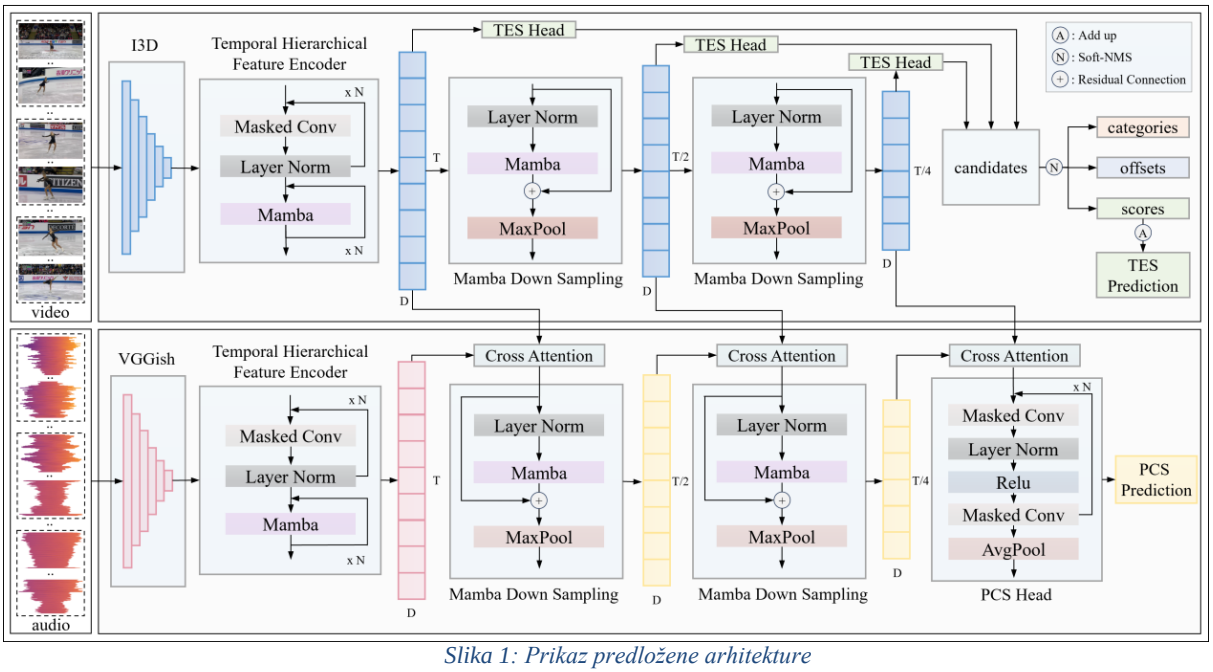
Automatsko ocenjivanje kvaliteta akcija (engl. *Action Quality Assessment* - *AQA*) predstavlja interdisciplinarnu oblast računarskog vida i mašinskog učenja čiji je cilj kvantitativna procena izvedbe sportskih ili umetničkih aktivnosti na osnovu video snimaka, zamenjujući ili dopunjujući subjektivnu ekspertsku procenu. Umetnički klizanje (*figure skating*) predstavlja posebno zahtevan domen za *AQA* sisteme jer zahteva istovremenu procenu dva različita aspekta nastupa.
Prema zvaničnim pravilima Međunarodne unije za klizanje (*ISU*), nastup se ocenjuje kroz dva odvojena sistema:

- Tehnička ocena (*Technical Element Score* - ***TES***) odražava kvalitet i tačnost izvođenja pojedinih tehničkih elemenata (skokova, pirueta i koraka) i formira se isključivo na osnovu vizuelnog opažanja, bez uzimanja muzičke pratnje u obzir.
- Ocena programskih komponenti (*Program Component Score* - ***PCS***) obuhvata artističke dimenzije nastupa, uključujući interpretaciju muzike i sinhronizaciju pokreta sa zvučnom podlogom, što čini audio kontekst konstitutivnim delom ocene.

Opisana podela ima direktne posledice po dizajn računarskih sistema za ocenjivanje. Uprkos tome, pregled relevantne literature pokazuje da su prethodne metode uglavnom ignorisale ovu razliku i stapale vizuelna i audio obeležja pri predviđanju oba tipa ocene, što nije u skladu sa stvarnim kriterijumima ocenjivanja i metodološki je nekorektno.
Pored toga, u literaturi su identifikovana još dva otvorena problema. Prvo, ***TES*** nije jedna globalna ocena već **zbir ocena svakog pojedinačnog tehničkog elementa tokom nastupa**, stoga je neophodno svaki element detektovati u video sekvenci i dodeliti mu ocenu. Prethodne metode po pravilu daju ukupnu *TES* predikciju bez faze detekcije tehničkih elemenata. Drugo, takmičarski nastupi traju i do četiri minuta, što postavljava izuzetno visoke zahteve za modelovanje dugoročnih vremenskih zavisnosti kojima konvencionalne *CNN* i *RNN* arhitekture nisu dorasle.
Navedeni problemi motivisali su istraživanje prikazano u radu *Wang et al*. (2025), koji predlažu dvostepenu *Mamba* piramidalnu mrežu (*Two-Stream Mamba Pyramid Network*). Ovo je arhitektura koja uvažava gore navedene kriterijume i time demonstrira da metodološka usklađenost sa domenskim znanjem dovodi do empirijski superiornijih rezultata.
Cilj ovog izveštaja jeste opis procesa reprodukcije eksperimenta opisanog u pomenutom radu, analiza postignutih rezultata u ograničenim računarskim uslovima, te kritičko razmatranje uočenih grešaka.

2. Pregled predložene arhitekture

Arhitektura sistema predložena u radu je prikazana na slici ispod i integriše dve paralelne grane obrade koje dele zajedničku osnovu za ekstrakciju obeležja, ali se razlikuju po modalitetima (tipovima informacija koje primaju) i ciljnim predikcijama.



Slika 1: Prikaz predložene arhitekture

U nastavku je dat sažet pregled komponenti relevantnih za razumevanje eksperimentalnih rezultata.

Ekstrakcija obeležja. Video obeležja dobijaju se primenom unapred istreniranog *I3D* modela na uzastopnim grupama frejmova, dok se audio obeležja ekstrahuju *VGGish* modelom. Oba seta obeležja projektuju se linearnim slojevima u zajednički *embedding* prostor dimenzije 1024.
Temporalni hijerarhijski enkoder (*THFE*). Svaki tok počinje enkoderom koji kombinuje modul temporalnog ugrađivanja (*TEM*), koji je niz *1D* konvolucionih slojeva sa *ReLU* aktivacijom i normalizacijom slojeva, i modul temporalnog prečišćavanja (*TRM*) zasnovan na maskirani *Mamba* blokovima. Enkoder čuva originalnu vremensku rezoluciju na izlazu.
Višeskalarna *Mamba* piramida (*MMP*). Centralni element arhitekture gradi piramidalni prikaz obeležja nizom *MDS* blokova (*Mamba Down Sampling*), pri čemu svaki nivo smanjuje vremensku rezoluciju *max-pooling* operacijom. Šest nivoa piramide omogućava istovremeno modelovanje kratkih i dugih akcijskih segmenata.
Unakrsna fuzija pažnje (*MCAF*). Na svakom nivou piramide, audio-vizuelni tok prima audio obeležja i spaja ih sa video obeležjima mehanizmom unakrsne pažnje, gde video obeležja preuzimaju ulogu upita (*query*), a audio obeležja generišu ključeve (*key*) i vrednosti (*value*). Ovime se obogaćuje vizuelna reprezentacija bez narušavanja vizuelnog toka za *TES*.
Glave za regresiju. *TES* glava istovremeno lokalizuje, klasifikuje i ocenjuje svaki tehnički element na svakom vremenskom trenutku i piramidnom nivou. *PCS* glava iz spojenih obeležja poslednjeg nivoa piramide jednim globalnim *poolingom* izvodi skalanu ocenu programa.
Zašto *Mamba*? Za razliku od *Transformer* arhitekture čija je računska složenost kvadratna u odnosu na dužinu sekvence, *Mamba* se zasniva na modelima prostora stanja (*State Space Models*) i postiže linearnu složenost, što je presudno za efikasnu obradu dugih takmičarskih snimaka bez znatnog povećanja memorijskog i vremenskog troška.

3. Podešavanje okruženja i identifikovani problemi

Reprodukcija eksperimenta izvršena je u *Google Colaboratory* okruženju (*Google Colab*), koje pruža besplatan pristup *GPU* resursima pogodnim za treniranje dubokih neuronskih mreža. U nastavku su detaljno opisani svi problemi koji su se pojavili tokom podešavanja okruženja, pristupa podacima i pokretanja eksperimenta, zajedno sa primenjenim rešenjima.

3.1 Problem pristupa skupu podataka

Autori rada navode da su koristili *FineFS* skup podataka koji sadrži 1604 video snimka visoke rezolucije (≈5000 frejmova po snimku pri 25 *FPS*), anotirana preciznim vremenskim granicama i ocenama svakog tehničkog elementa. Ukupna veličina skupa iznosi oko dva gigabajta, a autori su originalni link za preuzimanje objavili na kineskoj platformi za deljenje fajlova *Baidu NetDisk*.
Pristup *Baidu NetDisk* platformi izvana, bez kineskog broja telefona neophodnog za verifikaciju naloga nije moguć standardnim putem. Nakon neuspešnih pokušaja pristupa putem zvaničnog linka, problem je rešen preuzimanjem podataka putem usluge *BaiduDL* (*baidudl.com*), koja omogućava preuzimanje *Baidu* fajlova bez naloga uz jednokratnu naknadu od 1.99 *USD*. Na ovaj način preuzet je kompletni skup podataka (do 5 *GB*), koji je potom uploadovan na *Google Drive* i montiran u *Colab* sesiju, čime je obezbeđen stabilan pristup tokom treniranja.

3.2 Problem instalacije *Mamba* biblioteke

Mamba arhitektura zahteva specifičnu *Python* biblioteku (*mamba-ssm*) koja se kompajlira iz izvornog koda i oslanja na *CUDA* kernel ekstenzije. Instalacija u *Colab* okruženju odvijala se znatno duže nego što je to tipično za standardne *PyPI* pakete. Proces kompajliranja trajao je oko 40 minuta po sesiji.
Ovaj problem, iako nije blokirao dalji rad, uticao je na efikasnost rada u *Colab* okruženju zbog toga što *Google Colab* resetuje runtime sesiju nakon određenog perioda neaktivnosti, što je u par navrata zahtevalo ponovnu instalaciju.

3.3 Problem nekompatibilnosti verzija: *mamba-ssm* i *transformers*

Nakon uspešne instalacije paketa *mamba-ssm*, pri pokušaju uvoza modela pojavio se konflikt zavisnosti između verzije *transformers* biblioteke koju zahteva *Mamba* i verzije koja je bila predinstalirana u *Colab* okruženju.
Konkretno, instalacijom *mamba-ssm* automatski je prepisana instalirana verzija *transformers* paketom koji nije bio kompatibilan sa ostalim delovima koda. Greška se manifestovala kao *ImportError* pri pokušaju učitavanja određenih klasa iz transformers modula.
Primenjeno rešenje: Ručna reinstalacija kompatibilne verzije transformers biblioteke, nakon čega je neophodno bilo restartovati *Colab runtime* sesiju kako bi nove verzije paketa bile pravilno učitane u *Python* okruženje. Tek nakon ponovnog pokretanja sesije i ponovnog montiranja *Google Drive*-a, okruženje je postalo funkcionalno.

3.4 Problem ograničenosti *GPU* resursa

Originalni rad navodi da je model treniran tokom 50 epoha na *NVIDIA* A800 *GPU*-u, koji spada u visokoklasne istraživačke grafičke procesore sa 80 *GB VRAM*-a. *Google Colab* u besplatnoj verziji pruža pristup *GPU*-ima znatno skromnijih karakteristika (tipično *NVIDIA T4* ili *V100* sa 16 *GB VRAM*-a), uz vremensko ograničenje neprekidnog korišćenja.
Usled ovih ograničenja, model je treniran samo do 20. epohe, nakon čega su sačuvani parametri modela (*checkpoint*). Evaluacija i sve naredne analize zasnovane su na ovom istreniranom modelu. Ova razlika, koja se odnosi na 20 naspram 50 epoha, ima direktan i mjerljiv uticaj na sve dobijene metrike, što je detaljno razmatrano u poglavljima o rezultatima i analizi grešaka. Kako bi se sačuvao napredak i omogućio nastavak od dostignute tačke, implementiran je *checkpointing* - čuvanje modela nakon svake epohe, što je preporučena praksa za ovakve scenarije.

4. Rezultati evaluacije

4.1 Konfiguracija eksperimenta

Evaluacija je sprovedena nad validacionim skupom skupa podataka koji obuhvata 187 video zapisa. Korišćen je *checkpoint* sačuvan nakon 20. epohe treniranja, učitan iz *EMA* (*Exponential Moving Average*) verzije modela, što je standardna praksa koja obezbeđuje stabilniju procenu parametara u odnosu na direktno učitavanje poslednjeg stanja optimizatora. Konfiguracija modela odgovara originalnoj arhitekturi opisanoj u radu: šest nivoa *Mamba* piramide, 24 klase tehničkih elemenata, *embedding* dimenzija 512, maksimalna dužina sekvence 288.

4.2 Metrike temporalne lokalizacije i klasifikacije

Tačnost temporalne lokalizacije merena je pri deset pragova vremenskog preklapanja (*tIoU*), od 0.50 do 0.95. Rezultati su prikazani za dva scenarija: sa obaveznom ispravnom klasifikacijom tehničkog elementa i bez nje (*cls_ignore* režim koji meri isključivo kvalitet vremenskog razmeštanja).

tIoU prag	Sa klasifikacijom (%)	Bez klasifikacije (%)
0.50	67.26	84.47
0.55	66.37	83.21
0.60	65.21	81.30
0.65	63.39	78.17
0.70	59.84	72.11
0.75	56.86	67.30
0.80	52.89	61.10
0.85	47.20	53.73
0.90	37.59	42.02
0.95	17.07	18.42
Prosek	**53.37**	**64.18**

Tabela 1: Tačnost temporalne lokalizacije tehničkih elemenata pri različitim pragovima vremenskog preklapanja (tIoU), sa i bez obavezne klasifikacije elementa

Razlika od oko 17 procenata između dva scenarija pri nižim pragovima govori o tome da model u velikoj meri uspešno locira elemente u vremenu, ali ih pogrešno klasifikuje u kategoriju. Ovo je konzistentno sa ponašanjem nedovoljno istreniranog klasifikatora, gde detektor granica segmenata konvergira brže od klasifikatora kategorija, koji zahteva više epoha da nauči fine razlike između vizuelno sličnih elemenata (npr. različitih vrsta skokova).

4.3 Spirmanov koeficijent korelacije

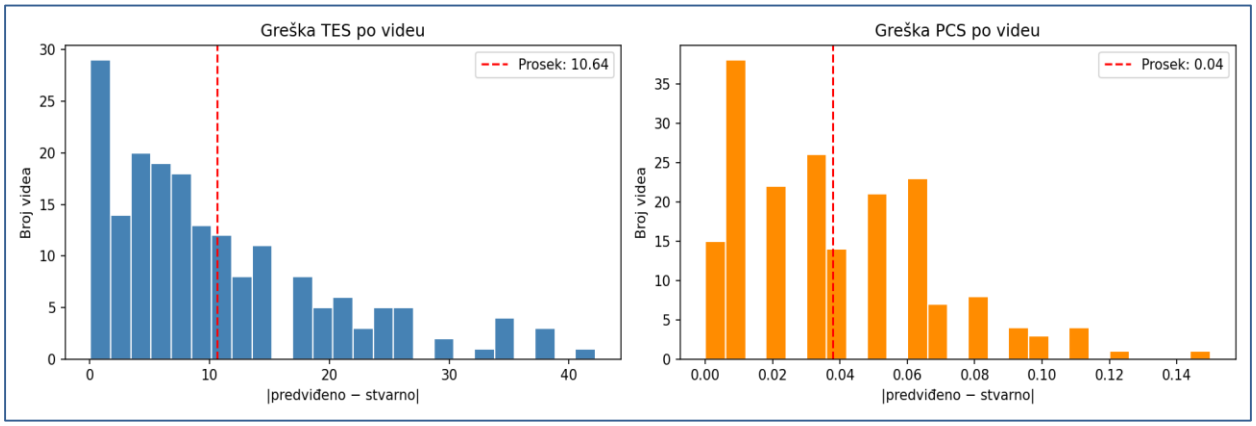
Evaluaciona skripta izveštava o tri posebna Spirmanova koeficijenta korelacije:

$\rho = 0.285$ - korelacija između predviđenih i stvarnih ocena pojedinih tehničkih elemenata (*per action*). Ova vrednost je relativno niska, što je razumljivo jer model pri nedovoljnom treniranju teži ka predviđanju vrednosti bliskih centru raspodele, potcenjujući elemente visokih ocena.
$\rho = 0.715$ - korelacija između predviđenih i stvarnih ukupnih *TES* vrednosti po nastupima (*per show*). Ova vrednost je znatno viša, što ukazuje da model uspešno rangira nastupe po ukupnom tehničkom kvalitetu, čak i kada su greške u apsolutnim vrednostima elemenata izražene.
$\rho = 0.971$ - korelacija između predviđenih i stvarnih *PCS* vrednosti po nastupima. Ovo je izuzetno visoka vrednost koja potvrđuje da je *PCS* predikcija robustna čak i pri svega 20 epoha treniranja. Ovaj rezultat empirijski validira ključnu arhitekturnu odluku autora - razdvajanje modaliteta pri predviđanju *TES* i *PCS* donosi merljiv doprinos već u ranim fazama treniranja.

5. Analiza slučajeva sa lošim performansama

5.1 Distribucija grešaka po uzorku

Slika 2 prikazuje raspodelu apsolutnih grešaka predviđanja *TES* i *PCS* vrednosti po video zapisu za ukupno 187 evaluiranih nastupa.



Slika 2: Raspodela TES i PCS grešaka po video zapisu

Raspodela *TES* greške pokazuje izraženu desnu asimetriju - najveći broj uzoraka (oko 29) ima grešku u opsegu 0-2, što ukazuje da model za većinu nastupa daje prihvatljive predikcije. Međutim, postoji jasno vidljiv dugačak desni rep koji se proteže do vrednosti 42.22, sa nekoliko uzoraka koji imaju greške u opsegu 30-42. Srednja vrednost greške od 10.64 znatno je viša od medijane (7.79), što je direktna posledica ovih ekstremnih slučajeva i potvrđuje da se ne radi o uniformno raspodeljenom šumu već o sistematskoj grešci za specifičnu podgrupu nastupa.
Raspodela *PCS* greške pokazuje bitno drugačiji karakter - vrednosti su koncentrisane u uskom opsegu (0.00-0.15), sa medijanom od 0.030 i maksimumom od 0.150. Raspodela je znatno manje asimetrična, što potvrđuje da je *PCS* predikcija konzistentno pouzdana bez obzira na karakter nastupa.
Ovaj kontrast između *TES* i *PCS* distribucija je posledica arhitekturne odluke da se audio modalitet uvede isključivo u *PCS* granu. *PCS* glava prima obogaćenu reprezentaciju već od prvih epoha treniranja, dok *TES* glava simultano optimizuje tri zadatka (lokalizaciju, klasifikaciju i ocenjivanje) oslanjajući se isključivo na vizuelna obeležja, što zahteva više iteracija za konvergenciju.

```
=== Statistika greške ===
       tes_err  pcs_err
count  187.000  187.000
mean    10.640    0.038
std      9.303    0.029
min      0.070    0.000
25%      3.970    0.010
50%      7.790    0.030
75%     14.515    0.060
max     42.220    0.150

=== Top 10 videa sa najvećom TES greškom ===
video_id  true_tes  pred_tes  tes_err  true_pcs  pred_pcs  pcs_err  n_el
     817    100.10     57.88    42.22      0.67      0.67     0.00    12
     968     89.54     51.25    38.29      0.71      0.64     0.07    12
     887     95.70     57.82    37.88      0.67      0.65     0.02    12
     920     97.02     59.41    37.61      0.66      0.64     0.02    12
     991     97.24     61.90    35.34      0.91      0.80     0.11    12
     922     89.32     53.98    35.34      0.73      0.67     0.06    12
     916    100.32     65.48    34.84      0.94      0.79     0.15    12
     839     88.44     54.48    33.96      0.71      0.68     0.03    12
     829    102.30     68.88    33.42      0.93      0.82     0.11    12
     945     98.34     68.65    29.69      0.86      0.76     0.10    12
```

Slika 3: Izlaz evaluacione skripte - deskriptivna statistika apsolutnih grešaka predikcije i deset video zapisa sa najvećom TES greškom

5.2 Zajednička karakteristika slučajeva sa najvećom greškom

Pregled deset uzoraka sa najvećom *TES* greškom otkriva konzistentan obrazac koji se ponavlja bez izuzetka:

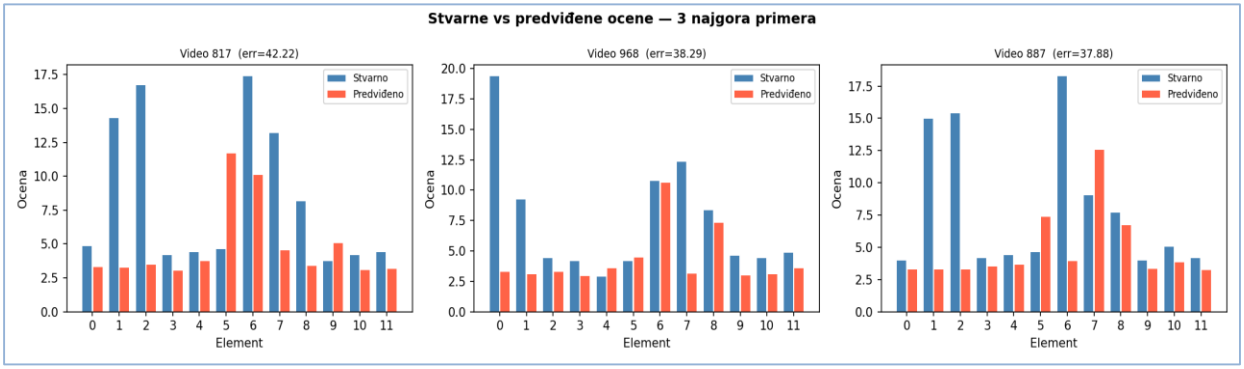
Video *ID*	*TES* stvarno	*TES* predviđeno	*TES* greška	*PCS* greška	Br. el.
817	100.10	57.88	42.22	0.00	12
968	89.54	51.25	38.29	0.07	12
887	95.70	57.82	37.88	0.02	12
920	97.02	59.41	37.61	0.02	12
991	97.24	61.90	35.34	0.11	12
922	89.32	53.98	35.34	0.06	12
916	100.32	65.48	34.84	0.15	12
839	88.44	54.48	33.96	0.03	12
829	102.30	68.88	33.42	0.11	12
945	98.34	68.65	29.69	0.10	12

Tabela 2: Deset video zapisa sa najvećom apsolutnom greškom TES predikcije

Svi uzorci imaju tačno 12 tehničkih elemenata, što identifikuje da se radi isključivo o nastupima slobodnog klizanja (*free skating*), dok kratki programi (*short program*) imaju 7 elemenata. Stvarne *TES* vrednosti kreću se u opsegu 88-102 boda, što odgovara gornjem kvartilu raspodele i predstavlja nastupe vrhunskih takmičara koji izvode elemente visokog tehničkog nivoa sa pozitivnim ocenama izvođenja (*GOE - Grade of Execution*). *PCS* greška za iste uzorke ostaje izuzetno niska, retko prelazeći 0.11, što potvrđuje da audio-vizuelna fuzija za artističku procenu funkcioniše pouzdano i nezavisno od tehničke složenosti nastupa.

5.3 Analiza grešaka po elementu za pet najgorih uzoraka

Slika 4 prikazuje poređenje stvarnih i predviđenih ocena za svih 12 tehničkih elemenata kod tri uzorka sa najvećom ukupnom greškom (video 817, 968 i 887). Svaki stub na grafikonu predstavlja ocenu jednog tehničkog elementa (od 0 do 11), a ukupna greška (42.22, 38.29, 37.88) je zbir razlika između plavih (stvarnih) i crvenih (predviđenih) stubova za svih 12 elemenata tog nastupa zajedno.



Slika 4: Poređenje stvarnih i predviđenih ocena za svih 12 tehničkih elemenata kod tri video zapisa sa najvećom ukupnom TES greškom (Video 817: err=42.22, Video 968: err=38.29, Video 887: err=37.88)

U narednoj tabeli prikazan je tehnički element sa pojedinačno najvećom greškom predikcije unutar svakog od pet video zapisa sa najlošijim ukupnim *TES* rezultatom. Za svaki nastup identifikovan je indeks elementa unutar sekvence, njegova stvarna ocena dodeljena od strane sudija, ocena koju je model predvideo, kao i apsolutna razlika između te dve vrednosti. Uočava se da model u svim slučajevima drastično potcenjuje ocenu najzahtevnijeg elementa, predviđajući vrednosti u opsegu 3.00-3.91 za elemente čije su stvarne ocene između 13.64 i 19.36.

Video ID	Najgori element (idx)	Ocena stvarno	Ocena predviđeno	Greška elementa
817	2	16.72	3.45	13.27
968	0	19.36	3.30	16.06
887	6	18.26	3.91	14.35
920	2	15.18	3.42	11.76
991	1	13.64	3.00	10.64

Tabela 3: Pet video zapisa sa najvećom apsolutnom greškom TES predikcije

```
=== Detaljna analiza 5 najgorih videa ===

—— Video 817 ——
  TES  stvarno=100.1  predviđeno=57.88  greška=42.22
  PCS  stvarno=0.67  predviđeno=0.67  greška=0.0
  Najgori element: idx=2, stvarno=16.72, pred=3.45, greška=13.27

—— Video 968 ——
  TES  stvarno=89.54  predviđeno=51.25  greška=38.29
  PCS  stvarno=0.71  predviđeno=0.64  greška=0.07
  Najgori element: idx=0, stvarno=19.36, pred=3.30, greška=16.06

—— Video 887 ——
  TES  stvarno=95.7  predviđeno=57.82  greška=37.88
  PCS  stvarno=0.67  predviđeno=0.65  greška=0.02
  Najgori element: idx=6, stvarno=18.26, pred=3.91, greška=14.35

—— Video 920 ——
  TES  stvarno=97.02  predviđeno=59.41  greška=37.61
  PCS  stvarno=0.66  predviđeno=0.64  greška=0.02
  Najgori element: idx=2, stvarno=15.18, pred=3.42, greška=11.76

—— Video 991 ——
  TES  stvarno=97.24  predviđeno=61.9  greška=35.34
  PCS  stvarno=0.91  predviđeno=0.8  greška=0.11
  Najgori element: idx=1, stvarno=13.64, pred=3.00, greška=10.64
```

Slika 5: Izlaz evaluacione skripte - detaljna analiza pet video zapisa sa najlošijim ukupnim TES rezultatom

Na osnovu analize identifikovanih slučajeva sa najvećom greškom, možemo da izdvojimo neke od osnovnih razloga zašto model ne funkcioniše dobro na ovim konkretnim nastupima.

Svi problematični primeri su nastupi slobodnog klizanja sa stvarnim *TES* vrednostima iznad 88 bodova, što u praksi podrazumeva izvođenje četvorostrukih skokova i složenih kombinacija sa visokim *GOE* bonusima. Ovakvi elementi su vizuelno veoma slični trostrukim skokovima, ali se ocenjuju znatno više. Pošto ih izvode isključivo vrhunski takmičari, u *FineFS* skupu podataka su znatno ređi od standardnih trostrukih skokova, što znači da ih je model tokom treniranja video premalo da bi naučio pouzdanu vezu između njihovog vizuelnog izgleda i visoke ocene. Umesto toga, pada na prosečnu vrednost koju je najčešće viđao, što je oko 3-4 boda i to je klasičan efekat regresije ka sredini (*regression toward the mean*), karakterističan za modele sa nedovoljnim brojem epoha treniranja.

Ovo je posebno vidljivo na Videu 968, gde je greška najveća upravo na elementu sa indeksom 0 (stvarno 19.36, predviđeno 3.30), četvorostrukom skoku izvedenom na samom početku programa. *TES* glava nakon samo 20 epoha nije imala dovoljno iteracija da nauči gornji kraj raspodele ocena i precizno razlikuje ovaj tip izvedbe od standardnog trostrukog skoka.

Konačno, važno zapažanje je da *PCS* greška za iste uzorke ostaje izuzetno niska. Video 817 ima TES grešku 42.22, ali PCS grešku 0.00. Ovo ukazuje na to da problem nije u kvalitetu video snimka, niti u grešci pri učitavanju podataka, već isključivo u tome da TES glava nije dovoljno konvergirala za nastupe vrhunskih takmičara sa elementima visokog tehničkog nivoa.

PCS i *TES* grane dele iste ulazne video i audio podatke, pa ako bi problem bio u kvalitetu snimka, lošem učitavanju podataka ili nekoj sistemskoj grešci u *pipeline*-u, očekivali bismo da su obe ocene jednako loše predviđene. Međutim, *PCS* predikcija je skoro savršena za isti nastup za koji je *TES* predikcija katastrofalna. To znači da model ispravno vidi i obrađuje snimak (razume muziku, prepoznaje opšti karakter nastupa i procenjuje artistiku), ali ne uspeva da iz istog tog snimka izvuče informaciju o tehničkoj vrednosti pojedinih elemenata.
Razlog jeste u prirodi arhitekture. *PCS* glava prima obogaćenu reprezentaciju koja uključuje i audio signal i konvergira brže jer predviđa jednu globalnu ocenu za ceo nastup. *TES* glava, s druge strane, mora da reši tri simultana zadatka: da locira svaki element u vremenu, prepozna o kojoj vrsti skoka se radi i dodeli mu preciznu ocenu, što zahteva znatno više epoha treniranja da bi sva tri zadatka konvergirala, posebno za retke i vizuelno zahtevne elemente kao što su četvorostruki skokovi.

6. Zaključak

Reprodukcija eksperimenta opisanog u radu *Wang et al.* (2025) uspešno je sprovedena u *Google Colaboratory* okruženju, pri čemu je model istreniran do 20. od planiranih 50 epoha i evaluiran na 187 video zapisa iz test skupa *FineFS* skupa podataka.
Ključni arhitekturni doprinos rada, razdvajanje vizuelnog toka za *TES* predikciju od audio-vizuelnog toka za *PCS* predikciju, empirijski je potvrđen već u ovim ograničenim uslovima. *PCS* predikcija dostigla je Spirmanov koeficijent korelacije $\rho = 0.971$, što je čak nešto više od vrednosti prijavljene u originalnom radu (0.96) i direktno potvrđuje da uvođenje audio modaliteta isključivo u *PCS* granu predstavlja metodološki ispravnu odluku. *TES* predikcija na nivou nastupa dostigla je $\rho = 0.715$, što znači da model ispravno rangira nastupe po tehničkom kvalitetu, ali još uvek ne predviđa precizne apsolutne vrednosti, što je očekivano ponašanje pri nedovoljnom broju epoha.
Analiza slučajeva sa najvećom greškom pokazala je konzistentan obrazac: model sistematski podbacuje isključivo na nastupima slobodnog klizanja sa *TES* vrednostima iznad 88 bodova, dok *PCS* greška za iste uzorke ostaje zanemarljivo mala. Uzrok leži u kombinaciji tri faktora: vizuelnoj sličnosti četvorostrukih i trostrukih skokova, njihovoj retkosti u skupu podataka, i nedovoljnom broju epoha da *TES* glava konvergira za gornji kraj raspodele ocena. Model u ovoj fazi treniranja pribegava regresiji ka sredini, predviđajući vrednosti oko 3-4 boda za elemente vredne 13-19 bodova.
Što se tiče praktičnih prepreka reprodukcije, geografsko ograničenje pristupa skupu podataka putem *Baidu NetDisk* platforme, nekompatibilnost verzija *mamba-ssm* i *transformers* biblioteka, te hardverska ograničenja besplatnih *GPU* resursa predstavljaju netrivijalne prepreke koje autori originalnog rada nisu eksplicitno adresirali. Dokumentovanje ovih prepreka i primenjenih rešenja doprinosi razumevanju praktičnih aspekata implementacije ovakvih arhitektura.
Kao pravci unapređenja izdvajaju se tri konkretna koraka.
Prvi je nastavak treniranja do 50. epohe od sačuvanog checkpoint-a. Pošto je model sačuvan nakon 20. epohe, nije potrebno počinjati iznova - treniranje se može nastaviti tačno od te tačke uz odgovarajuće GPU resurse.
Drugi pravac je podela grešaka po kategorijama tehničkih elemenata. Umesto jedne ukupne greške za sve elemente zajedno, trebalo bi posebno izračunati grešku za svaku kategoriju - posebno za *Axel* (najteži skok sa 4.5 okretaja u četvorostrukoj verziji), posebno za *Lutz* (odskok sa spoljne ivice uz pomoć drugog stopala), posebno za *Loop* (odskok sa spoljne ivice bez pomoći drugog stopala) i tako dalje. Na taj način bi se precizno utvrdilo za koje konkretne vrste skokova model greši najviše, umesto što se na osnovu ukupne greške samo pretpostavlja da su problematični četvorostruki skokovi generalno. Moguće je, na primer, da model bolje prepoznaje četvorostruki *Lutz* nego četvorostruki *Axel* zbog razlike u ulasku u skok, što bi bila vredna informacija za dalje unapređenje.
Treći pravac je primena *oversampling* tehnike za nastupe sa visokim ocenama. *Oversampling* znači da bi se tokom treniranja nastupima sa *TES* iznad 88 bodova namerno davala veća učestalost pojavljivanja, pa bi ih model viđao češće nego što ih zapravo ima u skupu podataka. *FineFS* skup sadrži nastupe različitih nivoa i četvorostruki skokovi su u manjini, pa model tokom standardnog treniranja nema dovoljno prilike da nauči njihove reprezentacije. Davanjem veće težine ovim nastupima, model bi brže naučio da ih razlikuje od trostrukih verzija istih skokova i da im dodeli odgovarajuće visoke ocene.